

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №2
За седьмой семестр
По дисциплине: «Интеллектуальный анализ данных»
Тема: Автоэнкодеры и визуализация выборки WDBC

Выполнил:
Студент 4 курса
Группы ИИ-26(2)
Семёнов А.В.
Проверил:
Никитин С.К.

Лабораторная работа: Автоэнкодеры и визуализация многомерных данных (на примере выборки WDBC)

Цель работы:

Изучить применение нейросетевых автоэнкодеров для снижения размерности и визуализации многомерных данных, а также провести сравнительный анализ их эффективности с методами t-SNE и PCA (метод главных компонент).

Характеристика датасета

Данные загружаются из `sklearn.datasets.load_breast_cancer`. Выборка содержит **569 объектов** и **30 числовых признаков**. В отличие от оригинального формата WDBC, где первые столбцы отведены под ID и целевую переменную, в реализации `scikit-learn` идентификатор удален, а диагноз вынесен в массив `target`:

- 0 — Злокачественные опухоли (Malignant, **M**);
- 1 — Доброкачественные опухоли (Benign, **B**).

Пропуски и некорректные значения в данных отсутствуют.

Класс	Обозначение в коде	Число объектов	Доля, %
Злокачественные	M / 0	212	37,26%
Доброкачественные	B / 1	357	62,74%
Всего	—	569	100,00%

30 признаков сформированы на основе 10 физических характеристик ядер клеток (радиус, текстура, периметр, площадь, гладкость, компактность, вогнутость, количество вогнутых точек, симметрия, фрактальная размерность). Для каждой характеристики рассчитываются три значения: среднее (μ), стандартная ошибка (SE) и наибольшее из измерений (*worst*).

2. Схема эксперимента и стандартизация

Стандартизация (Z-score)

Поскольку признаки измерены в разных масштабах, применяется стандартизация:

$$z_{ij} = \frac{x_{ij} - \mu_j}{s_j}, \quad s_j^2 = \frac{\sum_i (x_{ij} - \mu_j)^2}{n - 1}$$

Метки классов **не используются** при стандартизации, обучении моделей и подборе гиперпараметров (Unsupervised learning).

Разбиение выборки

Для обучения и валидации автоэнкодера данные разбиваются со случайным зерном $\text{seed} = 42$:

- **Обучающая выборка:** 341 объект (60%);
- **Валидационная выборка:** 114 объектов (20%);
- **Тестовая выборка:** 114 объектов (20%).
-

Важно: Статистики стандартизации (μ_j, s_j) вычисляются **строго по обучающей части**, после чего применяются к валидации и тесту. После выбора оптимальной архитектуры автоэнкодер обучается повторно на всей выборке (569 объектов) в течение найденного количества эпох для построения финальных графиков.

3. Архитектура и подбор параметров автоэнкодера




Рисунок 1 — Кривые обучения выбранных автоэнкодеров




Рисунок 2 — Двумерное и трёхмерное представления автоэнкодера

Автоэнкодер состоит из:

1. **Кодировщика (Encoder):** сжимает 30 признаков в k -мерный латентный вектор $h \in \mathbb{R}^k$ ($k \in \{2,3\}$).
2. **Декодировщика (Decoder):** восстанавливает исходный вектор $\hat{z} = g_\phi(h)$.

Математическая модель

$$h = f_\theta(z), \quad \hat{z} = g_\phi(h)$$
$$\text{MSE} = \frac{\sum_i \sum_j (z_{ij} - \hat{z}_{ij})^2}{n \times 30}$$

- **Слой:** Полносвязные (torch.nn.Linear).
- **Активация:** В скрытых слоях — ReLU. Латентный слой и выход декодировщика линейны (без активации), что позволяет кодировать отрицательные значения.
- **Оптимизатор:** Adam ($\beta_1 = 0.9, \beta_2 = 0.999, \varepsilon = 10^{-8}$), weight decay = 0.
- **Условия останова (Early Stopping):** Максимум 1500 эпох. Если валидационная MSE не улучшается в течение 150 эпох подряд, обучение прерывается с восстановлением лучших весов.

•

Результаты подбора гиперпараметров

Для поиска лучшей конфигурации исследовались две архитектуры при скоростях обучения $\eta \in \{0.001, 0.003\}$:

k	Архитектура Encoder	Learning Rate (η)	Лучшая эпоха	Train MSE	Val MSE
2	30–16–2	0.001	1428	0.262757	0.293421
2	30–16–2	0.003	538	0.270777	0.300369
2	30–32–16–2	0.001	402	0.293936	0.304206
2	30–32–16–2	0.003	222	0.288834	0.305639
3	30–16–3	0.001	486	0.220618	0.232095
3	30–16–3	0.003	223	0.214205	0.229429
3	30–32–16–3	0.001	393	0.198327	0.231716
3	30–32–16–3	0.003	238	0.184674	0.233804

Выбранные модели:

- Для $k = 2$: Архитектура 30–16–2–16–30, $\eta = 0.001$, эпоха 1428.
 - Val MSE: 0.293421, Test MSE: 0.287862.
- Для $k = 3$: Архитектура 30–16–3–16–30, $\eta = 0.003$, эпоха 223.
 - Val MSE: 0.229429, Test MSE: 0.216510.
 -

Примечание: Сравнение корректно в рамках заданной сетки гиперпараметров и

фиксированной инициализации (float64, single-thread CPU, deterministic mode).

4. Визуализация и методы сравнения

4.1. Автоэнкодер (АЕ)

Скрытые координаты (h_1, h_2, h_3) восстанавливают структуру данных. На полученных графиках классы М и В формируют выраженные кластеры, хотя на границах сохраняется перекрытие. Так как обучение шло "без учителя", разделение оптимизировалось только через задачу сохранения информации (реконструкцию).

4.2. Метод t-SNE

t-SNE ориентирован на сохранение **локальной структуры** (соседства объектов) путем минимизации KL-дивергенции.

- **Параметры:** `sklearn.manifold.TSNE(init="pca", learning_rate="auto", max_iter=1500, random_state=42)`.
- **Оценка качества:** Метрика *Trustworthiness* $T(10)$ по 10 ближайшим соседям (измеряет сохранение локальных связей из исходного пространства $\mathbb{R}^{30}$, максимум = 1).

Размерность (k)	Perplexity	KL-дивергенция	Trustworthiness T(10)
2D	20	1.037734	0.948451 (выбран)
2D	40	0.850243	0.946859
2D	60	0.729892	0.944845
3D	20	0.842602	0.965697
3D	40	0.659314	0.971986 (выбран)
3D	60	0.525900	0.970353

4.3. Метод главных компонент (РСА)

РСА производит линейное ортогональное проектирование. Собственные значения и векторы ковариационной матрицы вычисляются через `numpy.linalg.eig` и верифицируются с `sklearn.decomposition.PCA(svd_solver="full")`.

$$S = \frac{Z^T Z}{n - 1}, \quad T_k = ZV_k, \quad R_k = 100 \cdot \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^{30} \lambda_j}$$

Количество компонент (k)	Сохраненная дисперсия, %	Потерянная дисперсия, %	MSE (вся выборка)
2	63,24%	36,76%	0.366922
3	72,64%	27,36%	0.273155

5. Итоговое сравнение методик

Метод	k	MSE (вся выборка)	MSE (тест)	T(10) (вся выборка)
PCA	2	0.366922	0.360687	0.871348
Автоэнкодер	2	0.267602	0.287862	0.908507
t-SNE ($p = 20$)	2	—	—	0.948451
PCA	3	0.273155	0.280674	0.929201
Автоэнкодер	3	0.220465	0.216510	0.946183
t-SNE ($p = 40$)	3	—	—	0.971986




Рисунок 5 — Проекция WDBC на две и три главные компоненты

Ключевые выводы из сравнения:

1. Точность реконструкции (MSE):

- При $k = 2$ ошибка автоэнкодера на тесте **на 20,19% ниже**, чем у PCA (0.287862 против 0.360687).
- При $k = 3$ ошибка автоэнкодера **на 22,86% ниже**, чем у PCA (0.216510 против 0.280674).
- *Причина:* Нелинейная структура автоэнкодера позволяет эффективнее сжимать данные, учитывая сложные нелинейные зависимости признаков.

2. Сохранение локальных соседств ($T(10)$):

- Метод **t-SNE** показывает наилучшие результаты по метрике $T(10)$ (0.948 для 2D и 0.972 для 3D), оборачивая локальную топологию лучше остальных методов. Однако t-SNE не поддерживает трансформацию новых точек (transform) и не дает функций восстановления (MSE).

3. Особенности PCA:

- Прост, детерминирован и интерпретируем, но ограничен линейным подпространством. Потери дисперсии составляют от 27.36% до 36.76%.